

Today 4:08 PM



Project_Proposal_96_102....
PDF

Amar project er jonno related dataset (4+)list er link dau to
download dataset (like kaggle theke)



NLP Lab-20260918T104...
Zip Archive

Unzip my lab materials and analyse my taught nlp concepts, then plan and give me list of usagd model like tf idf, word2vec, bangla berd or any other suited models then give me the full project code with Python interface too(Streamlit or something), please do it seriously

Worked for 6m 11s >

আমি তোমার uploaded NLP Lab ZIP-এর সবগুলো material analyse করেছি—Lab 1 থেকে preprocessing, Lab 2 থেকে BoW/TF-IDF/N-gram, Lab 3 থেকে Word2Vec + NB + Logistic Regression, Lab 4 থেকে RNN/BiLSTM, আর Lab 5 থেকে Transformer/positional encoding/self-attention পর্যন্ত। এগুলোকে তোমাদের project proposal-এর সঙ্গে মিলিয়েই architecture বানিয়েছি।

সবচেয়ে গুরুত্বপূর্ণ বিষয় হলো তোমাদের proposal বর্তমানে **from-scratch learning**, NumPy-based implementation, custom tokenizer/representation/network এবং **pretrained/fine-tuned language model না ব্যবহার করার** constraint দিয়েছে।

Project_Proposal_96_102 +1

1. Final model plan

Model	Representation	Sequence-aware	Proposal status	Project role
Multinomial Naive Bayes	Word counts	No	✓ Core	Transparent probabilistic baseline
TF-IDF + Logistic Regression	TF-IDF	No	✓ Core	Main classical baseline
Word2Vec + Logistic Regression	Dense embeddings	No, mean pooling	✓ Core	Semantic representation experiment

Model	Representation	Sequence-aware	Proposal status	Project role
BiLSTM	Trainable embeddings	✓ Yes	Extension	Tests Lab 4 sequence modeling
Transformer Encoder	Embedding + positional encoding	✓ Yes	Extension	Tests Lab 5
BanglaBERT	Pretrained Bengali ELECTRA	✓ Yes	⚠ Optional benchmark	Only if teacher permits pretrained models

BanglaBERT is genuinely a pretrained Bengali ELECTRA checkpoint, so it should **not** be mixed into the proposal-compliant main experiment. 🤗 Hugging Face +1

Why this model ladder makes sense

TF-IDF + LR → Word2Vec + LR → BiLSTM → Transformer is actually a very good experimental progression for your lab syllabus.

Lab 3 itself demonstrates that mean/TF-IDF weighted embeddings still lose word order, which gives you a strong motivation for moving to BiLSTM and then Transformer.

For example:

কুকুর লোকটাকে কামড়েছে

লোকটা কুকুরকে কামড়েছে

A pure bag/mean representation can become very similar, while sequence-aware models can use ordering information.

2. Dataset strategy

আমি 4টা complementary dataset ধরে pipeline বানিয়েছি:

Multi-Labeled Bengali Toxic Comments — 16,073 samples; six toxicity labels: vulgar, hate, religious, threat, troll, insult. 🏠 GitHub +1

[Download Multi-Labeled Bengali Toxic Comments — Kaggle ↗](#)

Bengali Cyber Bullying Dataset — 6,010 samples across political, sexual, troll, threat and neutral categories.  Kaggle

[Download Bengali Cyber Bullying Dataset — Kaggle ↗](#)

BIDWESH — 9,183 manually translated/annotated regional-dialect instances covering Noakhali, Chittagong and Barishal, with hate/type/target annotations.  Mendeley Data +1

[Download BIDWESH — Mendeley Data ↗](#)

Bangla-ToCo — 1,004 context-aware Bengali comments with target comment, news title, metadata, predecessor/successor comments, and Toxic/Non-Toxic annotation.

 ScienceDirect +1

[Download Bangla-ToCo — Mendeley Data ↗](#)

একটা methodological issue আমি ইচ্ছা করে handle করেছি: the 16,073-sample Multi-Labeled dataset itself was constructed using other public Bengali datasets, so blindly merging everything can introduce duplicate/source leakage. The project therefore performs global normalized-text deduplication.  GitHub

আর Bangla-ToCo-কে default training merge-এর মধ্যে জোর করে ঢোকানো হয়নি; code এটাকে **external context-aware evaluation set** হিসেবে আলাদা রাখে। কারণ সেটার label schema শুধু Toxic/Non-Toxic।  ScienceDirect

3. সবচেয়ে গুরুত্বপূর্ণ design decision: `label_mask`

এটা project-এর একটা strong part।

তোমাদের সব dataset একই label দেয় না।

ধরো:

Dataset A:
hate = 1
threat = 0



কিন্তু dataset A আদৌ `sexist` annotate করেনি।

তাহলে:

```
sexist = 0
```



লিখে দিলে আমরা মিথ্যা assumption করছি যে sampleটি sexist নয়।

আমার code-এ এর পরিবর্তে:

```
sexist = unknown  
sexist_mask = 0
```



থাকে।

ফলে training loss এবং evaluation ওই label-টা ignore করে।

এটা heterogeneous multi-label dataset merge করার ক্ষেত্রে অনেক বেশি defensible approach।

তোমাদের proposal-এর target schema অনুযায়ী core labels:

```
hate_speech  
sexist  
threat  
bullying  
toxic
```



আর `neutral` আলাদা positive output নয়; সব label threshold-এর নিচে হলে সেটা neutral হিসেবে interface-এ দেখানো হয়। Proposal-এও Neutral/Hate Speech/Sexist/Threat/Bullying common schema করার কথা বলা হয়েছে। [Project_Proposal_96_102 +1](#)

4. ZIP-এর মধ্যে আমি কী বানিয়েছি

পুরো project structure:

```
Bangla_Toxic_Cyberbullying_Classifier/  
|  
├─ app.py  
├─ README.md  
├─ requirements.txt  
├─ requirements-core.txt  
├─ requirements-deep.txt  
|  
├─ data/  
|   └─ raw/
```



```
|   └─ processed/
|       └─ sample_dataset.csv
|
|─ artifacts/
|
|─ docs/
|   └─ lab_analysis.md
|   └─ model_plan.md
|   └─ dataset_plan.md
|   └─ project_proposal_alignment.md
|       └─ banglabert_optional.py
|
|─ scripts/
|   └─ smoke_test.py
|       └─ train_all.sh
|
|─ src/
|   └─ config.py
|   └─ preprocessing.py
|   └─ spelling.py
|   └─ labels.py
|   └─ data_prep.py
|   └─ metrics.py
|   └─ train.py
|   └─ predict.py
|   └─ evaluate_external.py
|       └─ models/
|           └─ tfidf_lr.py
|           └─ naive_bayes.py
|           └─ word2vec_lr.py
|               └─ deep_models.py
```

preprocessing.py

Lab 1-এর concept অনুযায়ী:

```
Unicode normalization
  ↓
HTML removal
  ↓
URL removal
  ↓
repeated character normalization
  ↓
Bengali/Banglish-aware regex
```



↓
tokenization

English-only regex না দিয়ে Bengali Unicode range support করেছি।

Lab 1-এর Levenshtein edit distance-ও আলাদা `spelling.py` -তে implemented আছে।

5. Core model implementations

TF-IDF + Logistic Regression

Lab 2-এর TF-IDF formulation ব্যবহার করে manual sparse representation এবং Lab 3-এর gradient-descent Logistic Regression style অনুসরণ করা হয়েছে।

অর্থাৎ core version-এ:

TF-IDF
↓
sigmoid
↓
gradient
↓
weight update



এখানে `sklearn.TfidfVectorizer` দিয়ে shortcut নেওয়া হয়নি।

Naive Bayes

Lab 3-এর:

$P(\text{class})$
 $P(\text{word} \mid \text{class})$
Laplace smoothing
log probability



pipeline অনুযায়ী from-scratch implementation করা হয়েছে।

Word2Vec + Logistic Regression

Lab 3-এর:

Word2Vec
↓



word embeddings
↓
mean document vector
↓
Logistic Regression

পদ্ধতিটা রাখা হয়েছে।

বাস্তব dataset বড় হওয়ায় implementation-এ **Skip-gram negative sampling** ব্যবহার করেছি যাতে Lab-এর full-vocabulary softmax-এর তুলনায় scale করা যায়; fundamental idea একই center-word/context learning।

6. BiLSTM এবং Transformer

Lab 4-এর sequence classification concept থেকে:

Token IDs
↓
Embedding
↓
BiLSTM
↓
Forward hidden + backward hidden
↓
Linear layer
↓
5 labels



Lab 5 থেকে:

Token IDs
↓
Embedding
↓
Positional Encoding
↓
Transformer Encoder
↓
Masked Mean Pooling
↓
Linear classifier
↓
5 labels



এগুলো pretrained নয়; নিজেদের dataset থেকেই embedding/weights train করবে।

7. Evaluation

Code শুধু accuracy না দেখিয়ে:

```
Micro Precision
Micro Recall
Micro F1
Macro F1
Per-label Precision
Per-label Recall
Per-label F1
Exact-match on fully annotated rows
```



দেবে।

Validation set থেকে independent threshold tuning-ও রাখা হয়েছে। যেমন:

```
hate_speech → 0.40
sexist      → 0.55
threat      → 0.35
...
```



একই 0.5 সব class-এর জন্য বাধ্যতামূলক নয়।

8. Streamlit interface

app.py -তে interface আছে:

```
| 🛡️ Bangla Toxic & Cyberbullying Classifier |
|
| Model: TF-IDF + LR ▼
| Threshold: 0.50
|
| বাংলা / Banglish comment
|
| comment লিখুন...
|
| [ 🔍 Classify ]
```



Label probabilities	
hate_speech	0.81
sexist	0.04
threat	0.67
bullying	0.72
toxic	0.91

সাথে preprocessed token-ও দেখাবে।

9. Run করার exact steps

ZIP extract করার পর:

</> Bash



Core models-এর জন্য

</> Bash



Linux/macOS:

</> Bash



Windows:

</> Bash



তারপর:

</> Bash



Dataset CSV/XLSX files রাখবে:

```
data/raw/
```



তারপর:

```
</> Bash
```



এতে তৈরি হবে:

```
data/processed/merged_dataset.csv  
data/processed/all_sources_dataset.csv  
data/processed/external_banglatoco.csv
```



Model train

TF-IDF + LR:

```
</> Bash
```



Naive Bayes:

```
</> Bash
```



Word2Vec + LR:

```
</> Bash
```



Deep models:

```
</> Bash
```



তারপর:

`</> Bash`



`</> Bash`



Streamlit:

`</> Bash`



10. BanglaBERT কোথায়?

Separate optional benchmark code রেখেছি:

`docs/banglabert_optional.py`



Official checkpoint:

[BanglaBERT — Hugging Face ↗](#)

BanglaBERT একটি pretrained Bengali ELECTRA discriminator checkpoint; তাই এটা তোমাদের current proposal-এর main model হলে “from scratch” claim আর ঠিক থাকবে না।

👍 Hugging Face +1

তাই report-এ ideally:

Main Experiments



Naive Bayes

TF-IDF + LR

Word2Vec + LR

BiLSTM

Transformer

Optional External Benchmark

BanglaBERT

এভাবে রাখবে।

11. আমি code test-ও করেছি

আমি generated code-এর:

Python syntax compilation 
TF-IDF + LR smoke test 
Naive Bayes smoke test 
Word2Vec + LR smoke test 



চালিয়ে দেখেছি।

তবে real dataset-এর final accuracy/F1 আমি claim করছি না, কারণ তোমার lab ZIP-এ actual Kaggle/Mendeley datasets ছিল না—শুধু lab materials ছিল। Smoke test-এ ছোট synthetic samples ব্যবহার করেছি।

পুরো project

[Download the complete Bangla Toxic & Cyberbullying Classifier project ZIP](#)

আর তোমার lab concepts-এর detailed mapping আছে:

docs/lab_analysis.md
docs/model_plan.md
docs/dataset_plan.md
docs/project_proposal_alignment.md



এই structure অনুযায়ী projectটা শুধু “একটা classifier” না; এটা তোমার Lab 1 → Lab 2 → Lab 3 → Lab 4 → Lab 5 শেখানো concepts দিয়ে তৈরি একটি proper experimental comparison pipeline।

Sources



Done — the complete project code is packaged here:

Download the complete project ZIP

It includes the Python source code, TF-IDF/LR, Naive Bayes, Word2Vec+LR, BiLSTM/Transformer modules, preprocessing, label mapping, training/evaluation scripts, Streamlit interface, requirements, sample data, and project documentation.



ami ki google colab na vs code e korbo, amar laptop 8bg purano lenovo 100 model

তোমার 8 GB RAM-এর পুরোনো Lenovo laptop হলে আমি hybrid approach recommend করব:

Best setup for তোমার project

VS Code → coding, preprocessing, dataset management, Streamlit UI

Google Colab → heavy model training

কাজ	কোথায় করবে
Python project/code লেখা	 VS Code
Dataset download/cleaning	 VS Code
Custom tokenizer	 VS Code
TF-IDF + Logistic Regression	 VS Code
Naive Bayes	 VS Code
Word2Vec	 VS Code, small settings
BiLSTM training	 Google Colab
Transformer training	 Google Colab
Large dataset merge	 VS Code / Colab
Accuracy/F1 evaluation	দুটোতেই

কাজ

কোথায় করবে

Streamlit interface

✓ VS Code


Final demo/presentation

✓ VS Code

আমার strong recommendation

তোমার laptop-এ **সবকিছু Colab-এ করো না**, আবার **সব training local-এও করো না**।

তোমার project-এর জন্য workflow হবে:



🖥️ তোমার 8 GB laptop-এ কী safely চলবে?

TF-IDF + LR → খুব সহজে চলবে।

Naive Bayes → খুব সহজে চলবে।

Word2Vec + LR → dataset বড় হলে কিছুটা সময় লাগতে পারে, কিন্তু সম্ভব।

BiLSTM → 8 GB RAM-এ training করলে laptop slow/hang হতে পারে, বিশেষ করে dataset বড় হলে।

Transformer from scratch → local laptop-এ করা আমি recommend করব না। Colab ব্যবহার করাই practical।

BanglaBERT → pretrained model হওয়ায় memory বেশি লাগতে পারে; তোমাদের proposal constraint-এর কারণেও এটাকে main model না রাখাই ভালো।

তোমাদের project-এর জন্য সবচেয়ে practical experiment

প্রথমে VS Code-এ:

1. Dataset cleaning
2. Dataset merging
3. Custom Bengali tokenizer
4. Label mapping
5. Train/validation/test split
6. TF-IDF + Logistic Regression
7. Naive Bayes
8. Word2Vec + Logistic Regression



এগুলো থেকে baseline result বের করবে।

তারপর একই processed dataset Google Colab-এ upload করে:

9. BiLSTM
10. Transformer



train করবে।

তারপর model files/results download করে আবার VS Code project-এ রাখবে:

```
artifacts/  
├─ tfidf_lr/  
├─ naive_bayes/  
├─ word2vec_lr/  
├─ bilstm/  
└─ transformer/
```



এবং Streamlit শুধু trained model load করে prediction করবে।

একটা গুরুত্বপূর্ণ বিষয়

Streamlit + training একই app-এর মধ্যে রাখব না।

ভালো architecture:

```
train.py
↓
saved model
↓
app.py
↓
Streamlit prediction
```



কারণ user comment দিলে Streamlit-এর মধ্যে আবার model train করানোর দরকার নেই।

🟢 তোমার জন্য আমার final recommendation

VS Code-কে main project environment বানাও।

Google Colab-কে training accelerator হিসেবে ব্যবহার করো।

তোমার laptop-এর 8 GB RAM অনুযায়ী:

```
VS Code
├─ preprocessing
├─ datasets
├─ TF-IDF
├─ Naive Bayes
├─ Word2Vec
├─ project organization
└─ Streamlit

Google Colab
├─ BiLSTM
└─ Transformer
```



এতে laptop-এর উপর চাপ কমবে, আবার project-এর full source code [free of cost](#) VS Code-এই থাকবে।

তোমার project-এর জন্য আমি চাইলে next step হিসেবে VS Code + Google Colab exact workflow দিতে পারি—কোন folder-এ dataset রাখবে, কীভাবে Colab-এ একই project চালাবে, trained model কীভাবে VS Code-এ ফিরিয়ে আনবে, এবং 8 GB RAM-এর জন্য batch size/sequence length/embedding size কত রাখা উচিত।



accha vs code e unzip kora code open korar por ki ki korte hobe like kon kon data set download korbo ,kon dataset kivabe use korbo vs code e

Worked for 22s >

হ্যাঁ। তোমার বর্তমান ZIP-এর actual code structure দেখে বলছি, তাই এখন কী করবে সেটা একদম exact ভাবে দিতে পারছি। তোমার `src/data_prep.py` filename দেখে dataset চিনে নেয়, তাই dataset-এর CSV/XLSX file-এর নামও গুরুত্বপূর্ণ।

তোমার project-এর intended dataset plan-এ ৪টা source আছে: Multi-Labeled Bengali Toxic Comments, Bengali Cyber Bullying, BIDWESH, এবং Bangla-ToCo। `data_prep.py` -তেও এই ৪টার জন্য আলাদা ingestion logic লেখা আছে।

1. প্রথমে project folder VS Code-এ open করো

ZIP extract করার পর:

Bangla_Toxic_Cyberbullying_Classifier/



VS Code-এ:

File → Open Folder → `Bangla_Toxic_Cyberbullying_Classifier`

তারপর left side-এ এরকম দেখাবে:

Bangla_Toxic_Cyberbullying_Classifier



```
|
|— app.py
|— requirements-core.txt
|— requirements-deep.txt
|
|— data
|   |— raw
|   |— processed
|
|— artifacts
|— docs
|— scripts
|
```

```
└─ src
   ├── data_prep.py
   ├── preprocessing.py
   ├── train.py
   └─ models
```

2. Python environment বানাও

VS Code terminal খুলে:

```
</> Bash
python --version
```

Python 3.10/3.11 হলে ভালো।

তারপর:

```
</> Bash
python -m venv .venv
```

Activate:

Windows

```
</> Bash
.venv\Scripts\activate
```

তাহলে terminal-এ এরকম আসবে:

```
(.venv) PS C:\...\Bangla_Toxic_Cyberbullying_Classifier>
```

তারপর:

```
</> Bash
python -m pip install --upgrade pip
pip install -r requirements-core.txt
```

এখন BiLSTM/Transformer install **কোরো না**। আগে classical models ঠিকমতো চালাই।
তোমার 8 GB laptop-এর জন্য এটিই safe।

3. কোন dataset download করবে?

আমি তোমাকে এখন ৪টা download করতে বলব, কিন্তু সবগুলো training-এ ব্যবহার করব না।

Dataset 1 — Main dataset

Multi-Labeled Bengali Toxic Comments

এটিই প্রথমে download করো।

[Kaggle — Multi-Labeled Bengali Toxic Comments ↗](#)

এতে toxic-related multiple labels আছে, তাই তোমার project-এর multi-label concept-এর সঙ্গে সরাসরি সম্পর্কিত।

Dataset 2 — Cyberbullying

Bengali Cyber Bullying Dataset

[Kaggle — Bengali Cyber Bullying Dataset ↗](#)

এই dataset-এ 6,010 Bengali cyberbullying social-media text আছে।  Kaggle

Dataset 3 — Regional hate speech

BIDWESH

[Mendeley — BIDWESH ↗](#)

এটিতে 9,183 manually translated/annotated regional Bangla instances আছে এবং Noakhali, Chittagong ও Barishal dialect cover করে। Hate/non-hate-এর পাশাপাশি hate type ও target annotation-ও আছে।  Mendeley Data

Dataset 4 — External test

Bangla-ToCo

[Mendeley — Bangla-ToCo ↗](#)

এটিতে 1,004 context-aware Bangla comments আছে এবং Toxic/Non-Toxic annotation-এর সঙ্গে news title, predecessor/successor comment ইত্যাদি context আছে।  Mendeley Data

এটাকে আমরা এখন training merge-এ দেব না। এটা পরে external evaluation-এর জন্য ব্যবহার করব।

4. Datasetগুলো কোথায় রাখবে?

এটা সবচেয়ে গুরুত্বপূর্ণ।

Project-এর মধ্যে:

```
data/  
└─ raw/
```



এই `raw` folder-এর ভিতরে dataset-এর CSV/XLSX files রাখবে।

Final structure ideally:

```
data/  
└─ raw/  
    ├── multi_labeled_bengali_toxic_comments.csv  
    ├── bangla_cyber_bullying.csv  
    ├── BIDWESH.csv  
    └── bangla_toco.csv
```



⚠️ ZIP file raw folder-এ রেখে দিও না

যেমন:

```
❌ data/raw/dataset.zip
```



না।

আগে ZIP extract করো, তারপর ভিতরের `.csv` / `.xlsx` file `data/raw/` -এ রাখো।

5. File নাম কেন important?

তোমার code-এ এই function আছে:

```
<> Python
```



▶ Run

```
def source_name(path: Path) -> str:
    n = path.name.lower().replace("_", "-")
```

তারপর:

 Python



 Run

```
if "multi" in n and "toxic" in n:
    return "multi_toxic"

if "bidwesh" in n:
    return "bidwesh"

if "toco" in n or "to-co" in n:
    return "banglatoco"

if "cyber" in n or "bully" in n:
    return "cyberbullying"
```

অর্থাৎ downloaded filename যদি weird হয়, code dataset চিনতে নাও পারে।

তাই simplest method:

Rename করো:

```
multi_toxic.csv
cyberbullying.csv
bidwesh.csv
toco.csv
```



তাহলে code easily identify করবে।

6. কোন dataset দিয়ে কী কাজ হবে?

এটাই তোমাদের project-এর actual data strategy:

```
Multi-Toxic
|
├── toxic
├── hate_speech
├── threat
├── bullying-related signals
|
```



▼
Main training corpus

Cyberbullying

|
├─ bullying
├─ threat
└─ toxic/non-neutral

▼
Additional training data

BIDWESH

|
├─ hate_speech
├─ gender/sex-related type → sexist signal
└─ violence/threat-related type → threat signal

▼
Regional hate-speech augmentation

Bangla-ToCo

|
└─ toxic / non-toxic
+
context

▼
External test

7. একটা খুব গুরুত্বপূর্ণ বিষয় — সব label সব dataset-এ নেই

তোমাদের canonical labels:

hate_speech
sexist
threat
bullying
toxic

কিন্তু ধরো Multi-Toxic dataset-এ threat আছে, কিন্তু sexist আলাদা করে annotate করা নেই।

তাহলে আমরা:

```
sexist = 0
```

ধরে নেব না।

Code-এ আছে:

```
sexist_mask = 0
```

মানে:

এই dataset sexist label annotate করেনি।

এটা খুব গুরুত্বপূর্ণ, কারণ না হলে model-কে ভুলভাবে false-negative শেখানো হবে।

8. এখন dataset preparation চালাবে

সব file data/raw/ -এ রাখার পর VS Code terminal-এ project root থেকে:

```
</> Bash
```

```
python -m src.data_prep
```

তখন output এরকম হবে:

```
[OK] multi_toxic.csv: 16073 rows  
[OK] cyberbullying.csv: 6010 rows  
[OK] bidwesh.csv: 9183 rows  
[OK] toco.csv: 1004 rows
```

তারপর:

```
data/processed/  
├─ merged_dataset.csv  
├─ all_sources_dataset.csv  
└─ external_banglatoco.csv
```

তৈরি হবে।

9. এই ৩টা file-এর কাজ কী?

`merged_dataset.csv`

এটাই main training dataset।

এখানে:

```
Multi-Toxic  
+  
Cyberbullying  
+  
BIDWESH
```



থাকবে।

`all_sources_dataset.csv`

সব source-এর combined version।

`external_banglatoco.csv`

শুধু Bangla-ToCo।

এটা training-এ যাবে না।

10. প্রথমে dataset check করবে

VS Code-এ Python terminal:

`</> Bash`

```
python
```



তারপর:

`</> Python`

```
import pandas as pd  
  
df = pd.read_csv("data/processed/merged_dataset.csv")  
  
print(df.shape)
```



`▶ Run`

```
print(df.columns)
print(df.head())
print(df["source"].value_counts())
```

তোমার দেখতে হবে:

```
source
multi_toxic
cyberbullying
bidwesh
```



এগুলো আছে কিনা।

আর:

</> Python



▶ Run

```
print(df[[
    "hate_speech",
    "sexist",
    "threat",
    "bullying",
    "toxic"
]].sum())
```

এতে প্রতিটি label কত positive sample আছে সেটা বুঝবে।

11. তারপর smoke test

Project-এ আগে থেকে test script আছে।

</> Bash



```
python scripts/smoke_test.py
```

এটা successful হলে পরের ধাপে যাবে।

12. প্রথম model — TF-IDF + Logistic Regression

তোমার laptop-এর জন্য এটাই প্রথম real model।

</> Bash



```
python -m src.train --model tfidf_lr --epochs 8
```

Model train হয়ে:

```
artifacts/  
├─ tfidf_lr.joblib  
└─ tfidf_lr_metrics.json
```



তৈরি করবে।

13. দ্বিতীয় model — Naive Bayes

</> Bash



```
python -m src.train --model naive_bayes
```

তারপর:

```
artifacts/  
├─ naive_bayes.joblib  
└─ naive_bayes_metrics.json
```



14. তৃতীয় model — Word2Vec + Logistic Regression

8 GB laptop হওয়ায় প্রথমে ছোট configuration দিয়েই চালাও:

</> Bash



```
python -m src.train --model word2vec_lr --epochs 2
```

এতে Word2Vec নিজেই dataset থেকে embedding শেখাবে।

15. এখনই BiLSTM/Transformer চালাবে না

এগুলো পরে Google Colab-এ করাই ভালো।

তোমার laptop:

8 GB RAM



তাই এই order রাখো:

STEP 1

Dataset preparation



STEP 2

TF-IDF + LR



STEP 3

Naive Bayes



STEP 4

Word2Vec + LR



STEP 5

Move processed data to Colab



STEP 6

BiLSTM



STEP 7

Transformer



STEP 8

Bring trained artifacts back



STEP 9

Streamlit



16. Streamlit কখন চালাবে?

সবচেয়ে আগে Streamlit চালালে model না থাকায় useful prediction করতে পারবে না।

কমপক্ষে TF-IDF model train হওয়ার পরে:

`</>` Bash

```
streamlit run app.py
```



Browser-এ app খুলবে।

তারপর comment দিতে পারবে:

এই লোকটা খুব বাজে কথা বলে।



অথবা Banglish:

tui ekta kharap manush



তারপর model probability দেখাবে:

Hate Speech	0.xx
Sexist	0.xx
Threat	0.xx
Bullying	0.xx
Toxic	0.xx



17. কিন্তু একটা code issue তোমাকে এখনই জানিয়ে রাখি

তোমার current `data_prep.py` -তে কিছু dataset-specific label mapping heuristic। বিশেষ করে `Cyberbullying` -এর category থেকে `bullying` এবং `BIDWESH`-এর `type` থেকে `sexist/threat` mapping করা হয়েছে।

যেমন:

`</>` Python



▶ Run

```
out["bullying"] = int("troll" in row or "sexual" in row)
```

এখানে `sexual = bullying` ধরে নেওয়া scientifically খুব clean mapping নয়।

তাই প্রথম run-এর পর তোমাদের actual downloaded dataset-এর **column names** এবং **unique label values** দেখে `data_prep.py` -এর mapping refine করা উচিত।

এই stepটা আমি strongly recommend করছি, কারণ report/viva-তে teacher জিজ্ঞেস করলে:

“Why did you map this source's label to bullying?”

তখন source annotation-এর সঙ্গে exact justification দেখাতে হবে।

18. Dataset download-এর updated option

বর্তমানে আরও নতুন Bangla toxicity datasets পাওয়া যাচ্ছে, যেমন BanglaHarassNet (2026), যেখানে Bangla/English/Banglish-এর 5,500+ annotated instances এবং আলাদা Hate Speech, Cyberbullying, Sexual Harassment, Trolling, Neutral files আছে।  Mendeley Data

আর BenCyber-এ 44,001 Bangla social-media records এবং Neutral, Harassment, Sexual Aggression, Hate Speech, Violent Extremism-এর মতো categories আছে।  Mendeley Data

তবে এখন এগুলো download করে existing code-এ ঢোকানোর দরকার নেই, কারণ তোমার বর্তমান `data_prep.py` -তে এদের জন্য source-specific adapter নেই। আগে existing 4-source pipeline stable করি; এরপর নতুন dataset add করতে চাইলে proper adapter লিখব।

এখন তোমার immediate কাজ

শুধু এই order-এ করো:

1. VS Code-এ project খুলবে
2. .venv বানাবে
3. requirements-core.txt install করবে
4. Multi-Toxic download করবে
5. Cyberbullying download করবে
6. BIDWESH download করবে
7. Bangla-ToCo download করবে
8. CSV/XLSX files → data/raw/
9. নাম রাখবে:
 multi_toxic.csv
 cyberbullying.csv
 bidwesh.csv
 toco.csv
10. python -m src.data_prep
11. python scripts/smoke_test.py
12. python -m src.train --model tfidf_lr --epochs 8

এই ১২টা step-এর পর থামবে। তখন `merged_dataset.csv` এবং TF-IDF result দেখে আমরা নিশ্চিত হবো dataset mapping ঠিক আছে কিনা। এরপর Naive Bayes, Word2Vec, তারপর Colab-এ BiLSTM/Transformer করব।



ChatGPT can make mistakes. Check important info.
[Cookie preferences](#)